



iimas

Universidad Nacional Autónoma de México
Instituto de Investigaciones en Matemáticas Aplicadas y en Sistemas



Módulo 5: Introducción al procesamiento de datos masivos

Instructor:
Dra. Blanca Vázquez
blanca.vazquez@iimas.unam.mx

What Happens on the Internet IN A SINGLE DAY?

● **zoom** 151M Meeting Hours

1.4B 🎥 Hours Streamed

2.5B **f** **facebook** Posts

3.5B 🐼 Snapchat Snaps

24.0B
💬 Texts sent

8.5B **Google** Searches

1.6B **tinder** Swipes

● **X** 500M Tweets

✉️
333 Billion
Emails sent

Figures rounded.
Source: Exploding Topics (Feb 2025)



What Happens on the Internet IN A SINGLE DAY?

● **zoom** 151M Meeting Hours

1.4B 📺 Hours Streamed

2.5B **facebook** Posts

3.5B **snapchat** Snaps

✉️
333 Billion
Emails sent


💬
24.0B
Texts sent

8.5B **Google** Searches


1.6B **tinder** Swipes

● **500M** Tweets


Figures rounded.
Source: Exploding Topics (Feb 2025)



Las 5v's del Big Data



Escenario real de las 5v's del Big Data




**¿Cómo almacenar y procesar
estos datos?**


¿Cómo almacenar y procesar datos masivos?




Apache Hadoop



Es un entorno de trabajo de software de código abierto que permite el procesamiento y análisis distribuido de grandes volúmenes de datos.




Apache Hadoop




Es un entorno de trabajo de software de código abierto que permite el procesamiento y análisis distribuido de grandes volúmenes de datos.

Sistema de archivos distribuido (Hadoop Distributed File System)




Apache Hadoop




Es un entorno de trabajo de software de código abierto que permite el procesamiento y análisis distribuido de grandes volúmenes de datos.

Sistema de archivos distribuido (Hadoop Distributed File System)




Apache Hadoop



Es un entorno de trabajo de software de código abierto que permite el procesamiento y análisis distribuido de grandes volúmenes de datos.

Sistema de archivos distribuido (Hadoop Distributed File System)




Servidores de fragmentos:

- Fragmentos continuos de 16 - 64 MB
- Réplicas de 2 a 3 veces




Apache Hadoop



Es un entorno de trabajo de software de código abierto que permite el procesamiento y análisis distribuido de grandes volúmenes de datos.

Sistema de archivos distribuido (Hadoop Distributed File System)



Garantizar:


- Persistencia
- Replicabilidad
- Disponibilidad




Map Reduce




Map Reduce



Map Reduce



Map Reduce




Procesamiento en paralelo
(Parallel processing)



¿Dónde se ejecutan estos procesos?


Arquitectura basada en clúster

Modelo
básico computacional




Arquitectura basada en clúster

Modelo
básico computacional




1 Gbps entre cualquier
par de nodos en un rack




Cada rack tiene de 16 - 64 nodos

Arquitectura basada en clúster

Modelo
básico computacional



2-10 Gbps entre racks
1 Gbps entre cualquier
par de nodos en un rack



Cada rack tiene de 16 - 64 nodos

Arquitectura basada en clúster



Imagen tomada de J. Leskovec, A. Rajaraman, J. Ullman: Mining of Massive Datasets


Google Data Centers: Building for Everyone



Video tomado de Google data centers


<https://youtu.be/l4Df09g-Xlc?si=y58iVG0SmZYRwabM>

Hadoop Ecosystem




Extensiones del marco de programación Map Reduce

Modelo de programación Map Reduce




Hadoop Map Reduce Job






Extiende el modelo de programación de Map Reduce

Hadoop Map Reduce Job



APACHE SPARK



Comparing Hadoop MapReduce and Spark



Hadoop
MapReduce

Fast

Batch Processing

Stores Data on Disk

Written in java

Low Cost



Apache
Spark

100x faster than MapReduce

Real-time Processing

Stores Data Memory

Written in Scala

High Cost

Unified engine for large-scale data analytics

GET STARTED

What is Apache Spark™?

Apache Spark™ is a multi-language engine for executing data engineering, data science, and machine learning on single-node machines or clusters.

Python

SQL

Scala

Java

R



Referencias

- Jure Leskovec, Anand Rajaraman and Jeffrey D. Ullman. Mining of Massive Datasets. Second Edition. Cambridge University Press, 2014. [Liga](#)
- Charu C. Aggarwal. Data Mining. Springer International Publishing, 2015. [Liga](#)
- Jules S. Damji, Brooke Wenig, Tathagata Das, Denny Lee. Learning Spark: Lightning-Fast Data Analytics, 2nd Edition, O'Reilly Media.

Contacto

Dra. Blanca Vázquez

blanca.vazquez@iimas.unam.mx

<https://github.com/blancavazquez>

